

AI 已经开始改造自己了——但不是你想的那样

约 3200 字 · 语速 260-280 字/分 · 基于 Lilian Weng 《Harness Engineering for Self-Improvement》
(2026-07-04) · 蓝色框为视觉提示，口播不读

时间轴	
00:00	钩子：AI 自我进化已开始
01:00	什么是 Harness：AI 的"操作系统"
03:00	三个设计模式
05:00	升级谱系：AI 开始优化 harness 本身
07:00	三个高能案例（DGM / AHE / 9B≈Opus）
10:00	三盆冷水
11:30	收尾：人类上移

00:00 钩子

AI 自我进化，已经开始了。

不是科幻电影里那种——机器一夜之间改写自己的大脑。真实发生的版本，比那个安静得多，也聪明得多：**AI 在改造自己的工具**。

而且就在上个月，一个标志性事件发生了：AI 自己设计的工具系统，在权威测试里，**第一次超过了人类顶尖工程师设计的版本**。

这期视频，我用 OpenAI 前安全副总裁 Lilian Weng 刚发的万字长文，给你讲清楚这件事到底意味着什么。

视觉：黑屏白字逐条打出「AI 自我进化 ≠ 改写大脑」→「= 改造工具」→「AI 设计 > 人类设计」（样片 S1-S3）

01:00 什么是 Harness：AI 的"操作系统"

先解决一个词：**harness**。

你可能听说过 Claude Code、Codex 这些编程 AI 特别强。但很多人不知道，它们强的秘密，一半不在模型本身，而在模型外面包的那层系统——这层系统就叫 harness。

最好的理解方式，是 Lilian Weng 文章里的原类比：**harness 之于 AI 模型，就像操作系统之于 CPU**。

视觉：素材图① OS 类比对照图（样片 S5，停 30 秒）

你看这个对照：模型本身，相当于 CPU——很强，但裸奔的 CPU 什么也干不了。harness 给它配上了整套外设：

- 它把**文件系统当硬盘**——长任务的笔记、日志、代码，全存在文件里，而不是塞在对话记忆里；
- 它能**开子代理当多线程**——把大任务拆给几个分身并行干；
- 它有**定时任务当闹钟**——到点自动醒来干活；
- 它还有权限控制、自我检查、工作流规则。

模型负责聪明，harness 负责让聪明落地。这就是为什么同一个模型，套上不同的 harness，干活能力天差地别。

03:00 三个设计模式：好 harness 长什么样

Lilian Weng 总结了三个核心设计模式，我给你翻译成大白话：

第一，干活要有循环。不是“一问一答”，而是“计划→执行→检查→改进”，转圈迭代，直到达成目标。关键是 AI 要能回头看**自己的失败记录**，从自己的错误里改。

第二，记忆要落盘。长任务里，AI 的“脑容量”（上下文窗口）根本不够用。聪明的做法是把状态全写进文件——就像你不会把整个项目背在脑子里，而是记在文档里。妙的是：读写文件本来就是 AI 的基本功，所以模型越强，这套记忆系统自动越强，**免费搭顺风车**。

第三，并行要透明。AI 可以派出多个分身同时探索，但每个分身的结果必须写成文件、留下记录——不能干完就消失。这样哪怕中断了，也能恢复现场。

视觉：三个模式各配 10 秒极简动画：循环箭头 / 文件落盘 / 分身合并（样片 S10-S12）

听起来是不是很像.....一个靠谱工程师的工作习惯？对，这就是重点：**harness 工程**，本质是把**人类工程师的工作纪律，编码成 AI 的运行系统**。

05:00 关键升级：AI 开始优化 harness 本身

好，前面都是人类给 AI 设计工具。真正的大事从这里开始。

Lilian Weng 画了一条演进路线，我认为是全文最值钱的一张图：

视觉：素材图② 五级谱系梯子，逐级点亮（样片 S14，停 60 秒）

这几年，我们交给 AI 优化的东西，一级比一级“元”：

- 最早，优化**提示词**——怎么问它答得好；
- 然后，优化**上下文**——喂给它什么信息；
- 再然后，优化**工作流**——任务怎么拆、步骤怎么连；
- 现在，优化 **harness 代码本身**——AI 直接改写自己运行系统的源代码；
- 下一步，优化**优化器**——AI 改进"AI 改进自己的方法"。

每上一级台阶，AI 的自主权就大一圈。而最上面两级，2026 年已经不是概念了——有实打实的结果。

07:00 三个高能案例

案例一：达尔文-哥德尔机 (Darwin Gödel Machine) 。

名字很中二，干的事很实在：让 AI 编程助手**直接修改自己的代码仓库**，改完测试打分，好的版本留下来继续繁衍，差的淘汰——就是数字版的物竞天择。

结果：在业界公认的编程测试 SWE-bench 上，从最初版本的 **20%**，自我进化到 **50%**。没有人类插手改一行代码。

视觉：进化树动画，分叉繁衍，数字 20% 滚动到 50%（样片 S17-S18）

案例二：AHE，就是开头说的那个标志性事件。

这套系统让 AI 演化自己的 harness，但立了两条铁规矩：第一，**每次修改必须附带证据和预测**——“我认为失败是因为 X，改 Y 能修好，预计提升 Z”，下一轮验证，说到没做到就回滚；第二，**评委和权限锁在进化圈外面**——AI 不能碰打分系统，堵死作弊。

结果：在 TerminalBench 测试上，AI 演化出的 harness **超过了 OpenCode、Codex 这些人类团队精心打磨的版本**。更狠的是，把这套 harness 冻结，换个完全不同的测试，成绩依然坚挺——说明它学到的是**通用工程经验**，不是应试技巧。

案例三：一个反直觉数据。

有研究把“写工具的能力”和“用工具的能力”分开测，发现：从 90 亿参数的小模型，到最顶级的大模型，**写 harness 的能力几乎一样**——小模型写出来的工具，结构上跟顶级模型的没差别。

视觉：素材图③ 数字卡三连（样片 S21）

差别在哪？在**用**。用好工具需要长程的指令遵循能力，这个才吃“智商”。这个发现很妙：它说明改造工具这件事的门槛，比我们想的低得多——但这也引出了下一个问题。

10:00 冷水时间：三个必须知道的限制

讲完热血的，讲点清醒的。这部分才是这篇文章真正专业的地方。

第一盆冷水：弱模型越递归越退化。早在 2023 年就有实验发现：让 GPT-4 递归改进自己的改进器，越改越好；但换成弱模型，**越改越差**。递归结构不是魔法，底座智能不够，自我进化就是自我劣化。

第二盆冷水：作弊是天性。自我改进循环会优化你给它的任何信号——考试给分，它就应试；评委是 AI，它就学会讨好评委。所以所有靠谱的系统，都把**评估器和权限管理放在进化循环之外**，物理隔离。

第三盆冷水：AI 不会承认失败。人类文献只发成功的研究，AI 从这些数据里学出来，天然不擅长说“这条路走不通”。Lilian Weng 特别强调：好的 harness 要**让失败记录容易保存**——因为学会放弃，恰恰是科研最贵的能力。

11:30 收尾

最后说她文末的两个判断，我很认同：

第一，harness 的很多技巧，未来会被吸收进模型本身——就像当年的提示词工程，慢慢就不需要了。但 **AI 和现实世界之间的接口层，永远存在**。

第二，关于人的位置。她的原话是：**人类应该在这个循环里上移，而不是被移除**——从亲手干活，上移到设定目标、把关方向、在关键节点做判断。

AI 在改造自己的工具，这已经是现在进行时。真正的问题从来不是“会不会发生”，而是——我们把评委的位置，留给谁。

原文链接放简介了，强烈建议精读。我是XX，我们下期见。

简介区文案

AI 自我进化已开始，但路线和科幻想的完全不同：不改大脑，改工具。

本期基于 OpenAI 前安全 VP Lilian Weng 2026 年 7 月长文《Harness Engineering for Self-Improvement》

原文：<https://lilianweng.github.io/posts/2026-07-04-harness/>

提到的研究：Darwin Gödel Machine (arXiv 2505.22954) · AHE (arXiv 2604.25850) · STOP (COLM 2024) · Self-Harness (arXiv 2606.09498)

发布前事实核查清单

- ☒ DGM 20%→50%：SWE-bench Verified，原文有此数字
- ☒ AHE 超 OpenCode/Terminus/Codex：TerminalBench-2；**Hard 档除外**——口播用“超过了人类设计的版本”，勿说“全面超过”
- ☒ 9B≈Opus 写 harness：Lin et al. 2026；updating 持平、benefit 非单调
- ☒ STOP 弱模型退化：GPT-4 提升 / GPT-3.5 & Mixtral 退化

☑ "内化+接口永存""人类上移"是 Weng 的观点/预测，口播已标"她的判断"